阅读笔记：参数高效微调与低秩适配

一、全量微调的成本

大模型全量微调要保存完整参数副本，显存与存储开销随参数量线性增长，多任务场景需要为每个任务保存一份权重。

二、低秩适配

低秩适配冻结预训练权重，在旁路注入两个低秩矩阵相乘得到的增量，只训练这两个小矩阵。推理时可以把增量合并回原权重，不增加延迟。

三、秩的选择

秩决定可训练参数量与表达能力。实践中从较小的秩开始，在效果不足时再提高，同时配合缩放系数平衡增量幅度。

四、与其他方法比较

适配器插入额外层会增加推理深度；前缀调优改变输入表示；低秩适配的优势是参数少且可以合并，缺点是秩较低时对复杂任务的拟合能力有限。

五、实践建议

在数据量较小的领域适配上，参数高效微调通常比全量微调更省资源，且多个任务可以共享同一底座。评估时要关注灾难性遗忘，建议保留一部分通用评测集。