阅读笔记：检索增强生成与稠密检索

一、动机

纯参数化模型把知识压缩在权重里，更新成本高，且难以给出出处。检索增强生成把外部文档作为非参数化记忆，生成时按需检索，答案可以回溯到原文。

二、双塔检索

稠密检索用两个编码器分别编码查询和文档，映射到同一向量空间，用内积或余弦相似度排序。训练常用对比学习，正样本是相关文档，负样本来自批内或难负样本挖掘。

三、混合检索的价值

纯向量检索擅长语义匹配，但对专有名词、编号、公式符号不敏感；关键词检索恰好相反。工业系统普遍把两路结果做融合，例如倒数排名融合 ＲＲＦ：对每一路按名次取倒数求和，无需跨模型校准分数。

四、结构化过滤

文献检索常带硬约束，例如年份区间、发表 ｖｅｎｕｅ、是否开源。把过滤条件下推到检索层，可以避免先召回再过滤造成的候选不足。

五、评估

常用指标包括召回率、平均倒数排名和答案的引用准确率。端到端评估需要同时看检索质量与生成是否忠实于检索到的证据。

六、工程要点

分块粒度直接影响效果：块太大引入噪声，太小丢失上下文。保留页码、段落编号等出处信息，是把检索结果变成可用证据的前提。