阅读笔记：注意力机制与 Transformer 架构

一、问题背景

循环神经网络按时间步串行处理序列，长距离依赖需要经过多步传递，梯度容易衰减，训练难以并行。卷积网络虽然可以并行，但要覆盖长距离依赖需要堆叠很多层。

二、核心思想

自注意力把序列中每个位置与所有位置直接相连，任意两个位置的交互路径长度为常数。缩放点积注意力用查询、键、值三组投影计算权重：查询与键做点积并除以维度的平方根，经 softmax 归一化后对值加权求和。除以平方根是为了避免点积随维度增大而使 softmax 进入饱和区。

三、多头机制

多头注意力把表示切分成多个子空间并行计算注意力，再拼接投影。不同头可以关注不同的语言现象，例如句法依存或指代关系。

四、位置编码

自注意力本身对顺序不敏感，需要显式注入位置信息。原始工作使用正弦位置编码，后续工作多用可学习位置嵌入或旋转位置编码。

五、残差与归一化

每个子层外围包裹残差连接和层归一化，使深层网络可以稳定训练。预归一化把归一化放在子层输入侧，训练更稳定，成为主流做法。

六、影响与局限

该架构成为大规模预训练语言模型的基础。局限在于注意力计算量随序列长度平方增长，长文本场景需要稀疏注意力、线性注意力或分块计算等近似方法。