面向向量数据库的混合检索自适应融合方法

作者：林知远，周可，陈一舟

会议：计算机学报

年份：2024

方向：向量数据库

代码：https://github.com/jiayalei225-svg/powercontext

摘要：单一稠密向量召回在专有名词、编号和罕见术语上容易失手，而纯词法检索又难以覆盖同义改写。本文提出一种自适应混合检索方法
AHR，在查询阶段分析字面密度与词频分布，动态决定稀疏分支和稠密分支的融合力度，并在候选集上执行轻量重排。方法直接构建于 seekdb 的 hybrid_search 之上，利用其内置 RRF
融合与标量过滤能力，无需额外的中间服务。在三个中文科技文献集合上的实验显示，AHR
相比固定权重 RRF 的 nDCG@10 提升 8.7%，端到端平均延迟保持在 42 毫秒以内。

关键词：向量数据库；混合检索；倒数排名融合；标量过滤；seekdb

1 引言

随着文献规模从数万篇增长到百万篇，检索系统同时面对两类查询：一类是语义化描述，例如“怎样让长文档检索更准确”；另一类是精确术语，例如模型缩写、数据集名称或会议名。稠密向量模型擅长前者，却会把含义相近但字面完全不同的编号混在一起；BM25
之类的稀疏检索擅长后者，但遇到同义表达时召回不足。工程上常见的做法是并行执行两路召回，再用倒数排名融合 RRF 合并结果。

固定融合参数带来一个被忽视的问题：当查询里出现罕见术语时，词法分支往往只有一两条真正相关的结果，此时它与稠密分支等权融合，反而稀释了精确命中。相反，对于抽象问题，词法分支命中大量噪声，也需要降低权重。本文关注的就是这种查询相关的融合调节，目标是在不增加在线服务数量的前提下提升首屏质量。

2 方法

AHR
由查询分析器、双路召回器和轻量重排器组成。查询分析器先做分词与词性过滤，统计候选词在语料中的文档频率，并计算查询中连续中文字符的比例。若存在文档频率低于阈值的术语，则判定为“字面敏感查询”，提高词法分支的融合权重；若查询以疑问词和抽象动词为主，则判定为“语义敏感查询”，提高向量分支权重。融合权重被限制在合理区间，避免单路召回完全主导。

双路召回直接调用 seekdb 的 hybrid_search 接口：query 参数承载全文条件与标量过滤，knn
参数承载向量近邻查询，rank 参数选择 RRF
并设置窗口大小。与传统方案相比，两个分支的候选在同一存储引擎内完成融合，省去了应用层合并、去重和排序的开销。标量过滤条件同时下推到两个分支，使年份、会议、方向与开源标记的约束在召回阶段就生效。

重排器只处理融合后的前若干条候选，使用查询与片段的最长公共子串比例、术语覆盖率和位置先验组成线性打分，再与融合分数加权求和。由于候选数量有限，重排的额外开销可以忽略，却能修正 RRF
对短片段的结构性偏好。

3 系统实现

系统将论文按句子边界切分为约三百八十字的片段，相邻片段保留七十字的上下文重叠，片段元数据包含论文编号、标题、年份、会议、方向、页码与开源标记。写入时按批次执行 upsert，并在批量导入结束后刷新索引。查询时，应用层只负责查询分析和结果解释，召回与融合完全交给 seekdb。该设计使得索引规模增长时，应用进程的内存占用保持稳定，也便于把同一套接口迁移到服务端部署。

4 实验

实验选取三个中文科技文献集合，覆盖数据库、自然语言处理与计算机视觉三个方向，每个集合包含两千到一万篇论文。基线包括纯向量检索、纯全文检索、固定权重 RRF 以及先向量后重排的两阶段方案。评价指标为 nDCG@10、MRR 和 Recall@20，延迟在单机、八核处理器、无 GPU 的环境下测量。

结果显示，AHR 在字面敏感查询上提升最明显，nDCG@10 相对固定权重 RRF 提升 8.7%，在语义敏感查询上提升 3.1%。消融实验表明，去掉查询分析器会使字面敏感子集回落约六个百分点，去掉轻量重排器则主要损失首条结果的准确率。由于两路召回共享同一索引，系统平均延迟为 42 毫秒，相比维护独立检索引擎的方案减少了一次网络往返和一次结果合并。

5 结论

本文把查询相关的融合调节引入向量数据库的原生混合检索路径，在保持系统简洁的同时改善了精确术语查询的排序质量。后续工作将研究跨语言查询的权重估计，以及把用户长期偏好作为软约束引入召回阶段，而不是仅在结果页做二次过滤。