检索增强生成中的记忆路由与证据筛选

作者：苏晚，何嘉树

会议：ACL

年份：2025

方向：检索增强生成

代码：https://github.com/jiayalei225-svg/powercontext

摘要：多轮检索增强生成系统需要同时处理用户偏好、任务进度和事实证据三类信息。把全部历史拼接到提示词中会造成上下文膨胀，而完全依赖向量相似度又会把过时偏好当成当前约束。本文提出记忆路由框架
MRF，将长期记忆拆分为偏好记忆与进度记忆，在每一轮根据查询意图选择读取路径，并对召回证据执行一致性筛选。框架使用 PowerContext
持久化记忆条目，以版本化文本记录偏好变更，使系统能够解释某条约束来自何时、哪一次交互。在中文多轮问答集合上，答案准确率相对全历史拼接提升 6.2 个百分点，提示词长度减少 38%。

关键词：检索增强生成；长期记忆；记忆路由；证据筛选；PowerContext

1 引言

检索增强生成把外部文档引入生成过程，但多数系统只把检索看作一次性动作。真实的研究助理场景往往持续数周：用户先关注某个方向，随后收窄到特定会议，最后要求只看带开源代码的论文。如果系统不能记住这些变化，用户就必须在每次对话中重复约束；如果系统不加区分地记住所有内容，过时偏好又会污染新的任务。

本文把这一问题概括为记忆路由：哪些记忆应该进入当前轮的决策，哪些应该留在后台。与简单的相似度检索不同，记忆路由需要考虑记忆的类型、时间与作用域。偏好类记忆带有稳定性，进度类记忆描述当前任务状态，事实类记忆则来自外部证据。三类记忆的读取策略并不相同。

2 框架

MRF
将记忆写入与读取分离。写入阶段，系统把用户显式设置整理为结构化偏好文本，并附加时间戳与来源说明；把每一次检索记录为进度记忆，包含查询、过滤条件和命中数量。读取阶段，路由器先判断当前查询是否需要偏好约束，再按时间倒序读取最新版本，避免旧设置覆盖新设置。

证据筛选模块负责检查召回片段与查询的一致性。它计算片段对查询术语的覆盖率，过滤只包含单个高频词的片段，并对同一论文的重复片段做合并。经过筛选的证据按论文聚合，生成带页码引用的上下文块，减少生成阶段的重复阅读。

记忆服务采用
PowerContext。每条记忆以带标记的纯文本保存，应用通过列表接口读取最近条目，并在本地按标记解析结构化内容。这种设计让记忆对人类可读、对程序可解析，也便于在记忆服务不可用时降级为无记忆模式，而不是阻塞主流程。

3 实验

实验构建了一个中文多轮问答集合，包含一百二十个会话，每个会话平均六轮。对照系统包括无记忆、全历史拼接、仅向量检索记忆三种方案。评价指标包括答案准确率、引用正确率和平均提示词长度。所有系统使用相同的生成模型与温度设置。

MRF 的答案准确率达到 71.4%，比全历史拼接高 6.2 个百分点；引用正确率提升 4.8 个百分点；平均提示词长度从三千一百字降至一千九百字。错误分析显示，剩余错误主要来自证据稀缺问题，而非记忆路由本身。当用户偏好发生冲突时，按时间读取最新版本的策略能够稳定选择当前设置。

4 结论

记忆路由把长期偏好与短期进度分开处理，在不增加提示词长度的前提下提升了多轮检索增强生成的稳定性。未来工作将探索记忆的自动过期与冲突检测，并研究在多用户共享文献库时如何隔离偏好作用域。