面向长上下文检索的分层分块与重排序

作者：顾南，唐棠，许之衡

会议：SIGIR

年份：2023

方向：信息检索

代码：无

摘要：固定长度切分会把定义、实验设置和结论拆散，导致检索命中片段缺乏自解释能力。本文提出分层分块方法
HCK，先按段落与句子边界构造基础片段，再以重叠窗口连接相邻片段，最后在查询阶段用交叉编码器对候选重排。在中文科技文献集合上，HCK 使 Recall@20 提升
5.4%，人工评估中的片段可读性显著优于固定窗口。我们还分析了片段长度、重叠比例与重排深度之间的权衡，为工程实现给出可复现的参数建议。

关键词：文本分块；重排序；长文档检索；句子边界；Recall@20

1 引言

长文档检索的第一道工序是分块。工程上最常见的做法是按固定字符数切分，并设置一定比例的重叠。这种做法实现简单，却忽略了论证结构的边界：一个定义可能跨两段，一组实验设置可能被切成三条片段。当检索系统把片段直接展示给用户时，缺乏上下文的片段会迫使用户回到原文查找，削弱检索结果的价值。

本文的目标不是追求更复杂的模型，而是寻找一种在索引成本、召回质量与可读性之间平衡的分块策略。我们以中文科技论文为主要对象，因为这类文本具有清晰的章节结构、较长的句子和大量专业术语。

2 方法

HCK
分三步构造片段。第一步按页抽取文本，保留页码信息；第二步以句号、问号、分号和感叹号为界切分句子，将句子累加到约三百八十个字符，超过阈值时在句子边界处截断；第三步从上一片段末尾保留约七十个字符作为重叠，使相邻片段共享上下文。与机械截断相比，句子边界保证了片段内部语义完整。

查询阶段采用两阶段排序。第一阶段使用混合检索获得候选，第二阶段用交叉编码器对查询与片段逐对打分。重排深度是一个需要权衡的参数：深度越大效果越好，但延迟线性增长。实验表明，在前五十条候选上重排可以取得大部分收益，继续增加深度带来的边际提升有限。

3 实验

实验使用两个中文文献集合，分别包含三千与八千篇论文。基线为固定窗口分块、段落分块和不重叠的句子分块。所有方法使用相同的向量模型与检索接口，只改变分块与重排策略。评价指标为
Recall@20、MRR@10 以及人工可读性评分。

结果显示，句子边界分块相比固定窗口在 Recall@20 上提升 5.4%，叠加交叉编码器重排后 MRR@10
提升
9.1%。重叠比例从零增加到七十字符时收益最明显，继续增加会带来索引膨胀而收益有限。片段长度在三百到四百字符之间表现稳定，过短的片段丢失上下文，过长的片段则稀释向量表示。

4 结论

分层分块与适度重排能够在较低工程成本下改善长文档检索质量。我们建议把页码与片段序号写入元数据，以便结果页提供可追溯的引用。后续工作将研究图表与公式的联合分块。