低资源场景下的中文科技文献关键词抽取

作者：程澄，罗一鸣

会议：软件学报

年份：2023

方向：自然语言处理

代码：https://github.com/jiayalei225-svg/powercontext

摘要：科技文献检索需要可靠的查询关键词，但低资源领域缺少标注数据。本文结合词性过滤、语料稀有度与领域词表，提出一种无监督的中文关键词抽取方法
KPX。方法先使用分词工具获得候选词与词性，过滤功能词和动词短语，再用候选词在语料中的出现次数衡量区分度，最后用左右邻接熵判断词语边界。在四万篇摘要上的实验显示，该方法在人工标注子集上的 F1 值为 0.61，优于 TF-IDF 与 TextRank 基线，并可作为全文检索的字面锚点。

关键词：关键词抽取；中文分词；语料稀有度；无监督方法；全文检索

1 引言

在文献检索系统中，用户输入往往是自然语言问题，而不是规范的关键词。系统需要从问题中抽取内容词，才能在全文索引中执行精确匹配。通用分词工具可以完成基础切分，但会把“混合检索”“向量数据库”等复合术语拆开，也会把“为什么”“怎么样”这类功能词保留下来，造成检索噪声。

低资源领域没有足够标注数据训练监督模型，因此本文选择无监督路线。我们的观察是：在特定语料中越罕见的词，越可能是查询的区分性线索；而功能词虽然常见，却不具备领域含义。将词性、频率和邻接信息结合起来，可以在不训练模型的情况下获得可用的关键词。

2 方法

KPX
包含候选生成、过滤与排序三个阶段。候选生成使用分词工具的搜索模式，保留名词、专名、动名词和英文词；过滤阶段剔除停用词表内的词，以及主要由“比、和、与、为、的、了、在、是、有”等功能字构成的候选；排序阶段统计候选在语料中的文档频率，低频候选获得更高权重，同时用左右邻接熵惩罚被错误拼接的长词。

除单篇文档内的统计外，方法还利用整个语料的稀有度。对于一个查询，系统从候选中选出在当前文献库中出现次数最少的一个，作为全文检索的字面锚点。这样做的原因是：常见词无法缩小候选范围，而稀有的专业术语往往直接指向目标文献。当所有候选都未出现时，系统退回纯向量检索，避免全文分支返回空集。

3 实验

实验语料包含四万篇中文论文摘要，覆盖计算机、自动化与材料三个领域。人工标注子集包含五百篇摘要，由两名标注者独立标注关键词，分歧通过讨论解决。基线包括 TF-IDF、TextRank
与基于词性过滤的 TF-IDF。评价指标为精确率、召回率与 F1。

KPX 在人工标注子集上的 F1 为 0.61，相比 TF-IDF 提升 7 个百分点，相比 TextRank 提升 11 个百分点。在检索应用中，使用稀有度选择字面锚点使精确术语查询的首条命中率提升约 9%，而对抽象问题的效果基本持平。错误分析表明，主要失败模式是领域新词被分词器拆散，未来可以引入新词发现模块。

4 结论

无监督关键词抽取在低资源科技文献场景中仍然有效。把词性、稀有度与邻接信息组合起来，可以为混合检索提供稳定的字面锚点。后续将评估领域自适应词表对跨学科查询的影响。